Departamento de Economía · Universidad de Pamplona

Estadística Descriptiva

Unidad 2 · Aplicación de la estadística descriptiva

Sadan De la Cruz
Universidad de Pamplona · 2026-II

Agenda

Datos agrupados: aplicación

Medidas de tendencia central

Medidas de dispersión

Cierre

1. Datos agrupados: aplicación

¿Qué son los datos no agrupados?

Definición

Son los datos tal como se recolectan: una lista de valores individuales, sin organizarlos en intervalos ni categorías. Cada observación conserva su valor exacto.

- También se conocen como **datos brutos** o **datos sin clasificar**.
- Son manejables cuando el número de observaciones es **pequeño** — no hay necesidad de resumir lo que ya se puede leer de un vistazo.
- Permiten calcular medidas de tendencia central y dispersión de forma **exacta**, sin ninguna aproximación.
- Ejemplo: años de experiencia de 6 comerciantes del centro de Cúcuta: 5, 8, 8, 12, 15, 20.

Datos agrupados vs. no agrupados

Criterio	No agrupados	Agrupados
Presentación	Lista de valores individuales	Intervalos de clase, cada uno con su frecuencia
¿Cuándo se usan?	n pequeño, o se necesita el valor exacto de cada dato	n grande, o variable continua cuyos valores casi nunca se repiten
Precisión	Exacta: no se pierde información	Aproximada: la marca de clase representa a todos los datos de su intervalo
Cálculo de medidas	Directo sobre cada valor	Requiere marca de clase, límites reales y demás herramientas de esta unidad

La elección no es de forma: depende del volumen de datos y de si se puede pagar el costo de la aproximación a cambio de legibilidad.

¿Qué son los datos agrupados?

Definición

Cuando el número de observaciones es grande o la variable es cuantitativa continua, los datos se organizan en **intervalos de clase** en lugar de listar cada valor individual. A cada intervalo se le asocia el número de observaciones que caen dentro de él.

- Se pasa de *"cuál es el valor exacto de cada dato"* a *"cuántos datos caen en cada rango"*.
- Es el procedimiento habitual con variables como ingresos, producción o hectáreas cultivadas, que rara vez se repiten exactamente entre observaciones.
- El objetivo es **resumir la información sin perder la capacidad de calcular** medidas de tendencia central y de dispersión sobre ella.

Del dato bruto a la información estructurada

- Con grandes volúmenes de datos, la información individual pierde valor si no se interpreta sistemáticamente (Gómez Giraldo, 2021, p. 48).
- **Marca de clase (X_i):** punto medio representativo de cada intervalo — el valor que *representa* a todos los datos de esa clase en los cálculos posteriores.
- **Frecuencia acumulada (F_i):** número de datos acumulados desde la primera clase hasta la clase i, inclusive.
- Estos dos elementos son los insumos para calcular promedios y variabilidad.

Límites teóricos vs. límites reales

Regla de Sturges

$m = 1 + 3{,}3 \log n$ — el número de intervalos debe ser un entero que cubra todo el rango.

Error de agrupamiento

Lo que se gana en legibilidad se pierde en precisión (p. 54). Un intervalo demasiado amplio puede ocultar pobreza extrema al mezclar hogares de subsistencia con productores medianos.

- **Límite real (L_i):** semisuma entre un límite superior teórico y el inferior del siguiente. Para datos con 2 decimales, el ajuste es de 0,005.

Ejemplo: del límite teórico al límite real

Datos hipotéticos: edad (años cumplidos) de beneficiarios de un programa social en Cúcuta. Intervalos teóricos (enteros): $18-27$, $28-37$, $38-47$, $48-57$.

Calcular el límite real entre dos clases

Se promedia el límite superior de una clase con el límite inferior de la siguiente. Entre $18-27$ y $28-37$:

$$L_{real} = \frac{27+28}{2} = 27{,}5$$

Intervalo teórico	Intervalo real
18 – 27	17.5 – 27.5
28 – 37	27.5 – 37.5
38 – 47	37.5 – 47.5
48 – 57	47.5 – 57.5

Con datos enteros el ajuste es $\pm 0{,}5$*; con 2 decimales (p. ej. miles de pesos) es* $\pm 0{,}005$ *— así se obtiene* $L_i = 39{,}995$ *en el ejemplo de la mediana.*

Ejemplo: ingresos mensuales de vendedores informales

Dato hipotético con fines ilustrativos, $n = 100$.

Intervalo (miles COP)	f_i	F_i	X_i	$f_i \cdot X_i$
[600 – 800)	25	25	700	17.500
[800 – 1.000)	45	70	900	40.500
[1.000 – 1.200)	20	90	1.100	22.000
[1.200 – 1.400)	10	100	1.300	13.000
Total	**100**			**93.000**

Ejercicio propuesto

A partir de una distribución hipotética de hectáreas de cacao en Tibú (rango 2–18 ha, $n = 50$), aplique la regla de Sturges y construya la tabla de frecuencias completa.

2. Medidas de tendencia central

Media, mediana y moda

Medida	**No agrupados**	**Agrupados**
Media $\bar{X}$	$\frac{\sum X_i}{n}$	$\frac{\sum f_i X_i}{n}$
Mediana M_e	Dato central	$L_i + \left(\frac{n/2 - F_{i-1}}{f_i} \right) A$
Moda M_o	Valor más frecuente	$L_i + \left(\frac{\Delta_1}{\Delta_1 + \Delta_2} \right) A$

Elementos de la fórmula: media y mediana

- n: número total de observaciones (tamaño de la muestra o población).
- f_i: frecuencia absoluta de la clase i — cuántos datos caen en ese intervalo.
- X_i: marca de clase de la clase i — el punto medio del intervalo.
- L_i: **límite inferior real** de la *clase mediana* — el intervalo donde se ubica el dato central.
- F_{i-1}: frecuencia acumulada **hasta la clase anterior** a la clase mediana.
- A: amplitud (ancho) del intervalo de clase.

La clase mediana es aquella cuya frecuencia acumulada F_i alcanza por primera vez $n/2$.

Elementos de la fórmula: moda

- **Clase modal:** el intervalo con mayor frecuencia absoluta, f_m.
- L_i: límite inferior real **de la clase modal**.
- $\Delta_1 = f_m - f_{m-1}$: diferencia entre la frecuencia de la clase modal y la de la clase **anterior**.
- $\Delta_2 = f_m - f_{m+1}$: diferencia entre la frecuencia de la clase modal y la de la clase **siguiente**.
- A: amplitud del intervalo modal.

Comparación entre fuentes

Estadística UNAL (Gómez Giraldo, 2021, p. 77) usa Δ_1, Δ_2; *Levin & Rubin* usan d_1, d_2 para exactamente el mismo concepto.

Asimetría y el “ciudadano típico”

La media es sensible a valores atípicos

Coeficiente de asimetría de Pearson: $SK = \dfrac{\bar{X} - M_o}{S}$ (p. 95) — revela si la distribución se sesga por valores extremos de pobreza o riqueza.

- La **mediana** no se deja arrastrar por los extremos: representa mejor al habitante promedio en contextos de informalidad.

Ejemplo resuelto: mediana del gasto en transporte

Escenario hipotético. Clase mediana: intervalo 40–50 mil pesos.

Datos

- $L_i = 39{,}995$ — límite inferior real de la clase mediana
- $n = 80$ — total de hogares encuestados
- $F_{i-1} = 30$ — hogares acumulados **antes** de esta clase
- $f_i = 20$ — hogares dentro de esta clase
- $A = 10$ — amplitud del intervalo

$$M_e = L_i + \left(\frac{n/2 - F_{i-1}}{f_i}\right) A = 39{,}995 + \left(\frac{80/2 - 30}{20}\right) \cdot 10 = 39{,}995 + 5 = 44{,}995$$

Interpretación: el 50 % de los hogares gasta aproximadamente 45.000 COP o menos en transporte.

Ejercicio propuesto

Calcule la moda hipotética del peso de carga de cerámica exportada por el puente Atanasio Girardot. El intervalo modal es 10–15 toneladas ($L_i = 10$, $A = 5$), con $f_m = 40$, $f_{m-1} = 25$, $f_{m+1} = 30$.

3. Medidas de dispersión

Variabilidad como riesgo económico

Un promedio sin dispersión es un espejismo

Una media de ingresos alta puede ocultar profundas brechas sociales si la dispersión es elevada.

- **Rango:** $R = X_{max} - X_{min}$
- **Varianza:** $S^2 = \dfrac{\sum f_i (X_i - \bar{X})^2}{n}$
- **Desviación estándar:** $S = \sqrt{S^2}$
- **Coeficiente de variación:** $CV = \dfrac{S}{\bar{X}} \cdot 100\,\%$

Estabilidad y estructura regional

- El *CV* permite comparar la estabilidad de precios entre mercados distintos (hipotético): un *CV* mayor implica mayor riesgo e incertidumbre.
- Una desviación estándar alta en la tasa de desempleo local indicaría inestabilidad estructural que la política pública no ha logrado mitigar.

Ejemplo resuelto: empleados en locales comerciales

Dato hipotético con fines ilustrativos.

X_i **(empleados)**	f_i	$X_i f_i$	$(X_i - \bar{X})^2 f_i$
2	10	20	40
4	20	80	0
6	10	60	40
Total	**40**	**160**	**80**

$\bar{X} = 4$; $S^2 = 2$; $S \approx 1{,}41$; $CV = 35{,}25\,\%$ (variabilidad moderada).

Ejercicio propuesto

Calcule el coeficiente de variación de una producción hipotética de palma de aceite en el Catatumbo (media 25 ton/ha, desviación 5.5 ton/ha). ¿Qué tan estable es la producción frente a estándares nacionales?

4. Cierre

Para llevar

- El agrupamiento de datos siempre implica un balance entre legibilidad y precisión (error de agrupamiento).
- Media, mediana y moda responden preguntas distintas: elegir la correcta depende de la presencia de valores atípicos.
- Ninguna medida de tendencia central es completa sin una medida de dispersión que la acompañe.
- El coeficiente de variación permite comparar riesgo/estabilidad entre contextos distintos, incluso con escalas diferentes.

Referencias

- Gómez Giraldo, H. (2021). *Estadística* (2.ª ed.). Universidad Nacional de Colombia.
- Levin, R. I. & Rubin, D. S. *Estadística para administración y economía*.

Las menciones a DANE, GEIH y Cámara de Comercio son contexto territorial ilustrativo; los datos numéricos asociados son hipotéticos.